Отчет по Заданию 1: Отчёт по задачам и Skills

Ход экспериментов:

1.Сгенерировно 100 задач с фиксированным sed = 42, чтобы набор данных был одинаковым для всех прогонов.

2.Без скилла: Я дважды попросил агента сделать отчет по жесткому ТЗ (3 листа: сводка, просроченные, ближайшие). Оба раза агент писал Python-код с нуля, устанавливал библиотеки и сам считал статистику.

3.Со скиллом: Я сгенерировал детерминированный Python-скрипт generate_report.py и файл SKILL.md с описанием. Попросил агента короткой фразой «сделай отчёт по задачам в Excel». Агент нашел скилл и просто запустил скрипт.

4. Эксперимент с description: Поменяв описание скилла на упрощенное (и имя на непонятное. helper_thing), после чего агент перестал замечать скилл и снова начал писать код. С хорошим описанием сразу разбирается

Критерий	Без skill (1.2)	Со skill (1.5)
Цифры совпадают между прогонами	Нет. В первом прогоне выполнено 37, просрочено 10. Во втором — выполнено 36, просрочено 13.	Да. Скрипт детерминированный, цифры всегда одинаковые (36 выполнено, 13 просрочено).
Формат отчёта совпадает	Формат отчёта совпадает	Да. Формат жестко задан в коде generate_report.py.

Цифры верны (сверка с API)	Нет. Из-за самостоятельного подсчета агент путался в датах (например, записывал сегодняшние задачи в просроченные).	Да. Скрипт использует datetime и точно фильтрует по датам и статусам.
Шаги и вызовы tools	Много шагов (10+). Установка библиотек, написание кода, чтение API, отладка ошибок.	Мало шагов (1-2). Агент читает SKILL.md, запускает готовый скрипт и отдает результат.
Токены(/stats)	Высокий расход (агент генерирует много кода и рассуждений).	Низкий расход (агент только формирует команду запуска).
Время	Несколько минут на каждый прогон.	Пара секунд.
Как подхватывается skill с разными description	-	С хорошим описанием (make_report) — подхватывается сразу. С пустым описанием и именем helper_thing — игнорируется, агент пишет код сам.

Вывод:
Использование скиллов полностью решает проблему нестабильности LLM. Детерминированный скрипт гарантирует правильность цифр и формата, а агенту остается только роль "диспетчера", который запускает скрипт. Без скилла агент тратит много времени и токенов, но всё равно допускает

Отчет по задачам TODO (на 2026-11-04)					
Показат	**Значение**				
Всего за	100				
Выполне	36				
Выполне	36%				
Не выпо	64				
Просроч	13				
Разбивка по приоритетам					
Приорит	Всего	Выполне	Доля выполнения		
High	34	12	35.3%		
Normal	38	17	44.7%		
Low	28	7	25%		

ошибки в логике и математике.

Без скила report_no_skill.xlsx:

Показатель	**Значение**		
Всего задач	100		
Выполнено	36 (36.0%)		
Не выполнено	64		
Просрочено	13		
Приоритет	Всего	Выполнено	%
High	34	12	35.3%
Normal	38	17	44.7%
Low	28	7	25.0%

Со скилом и описанием report_skill.xlsx:

Показатель	Значение		
Всего задач	100		
Выполнено	36 (36.0%)		
Не выполнено	64		
Просрочено	13		
Приоритет	Всего	Выполнено	%
High	34	12	35.3%
Normal	38	17	44.7%
Low	28	7	25.0%

Со скилом, но без описания(такой же вывод) report_skill 2.xlsx: